1.Duży (> 1000 elementów) zbiór dokumentów tekstowych w języku angielskim

```
def generete_texts():
    for i in range(1001):
        gen = MarkovTextGenerator()
        file_name = 'text' + str(i) + '.txt'
        path = 'texts/' + file_name
        string_to_write = gen.gen_text(100)
        file = open(path, 'w')
        file.write(string_to_write)
        file.close()
        # os.remove(path)
```

- 2.Słownik słów kluczowych (termów)- vocab w funkcji generate_bow()
- 3. Wektor cech bag-of-words bag_vector[i] w funkcji generate_bow()
- 4. Macierz wektorów $A_{m \times n} = [\mathbf{d}_1 | \mathbf{d}_2 | \dots | \mathbf{d}_n]$ cech term-by-document matrix transpose_list w funkcji generate_bow()

```
def word_extraction(sentence):
    ignore = ['a', "the", "is"]
    words = re.sub("[^\w]", " ", sentence).split()
    cleaned_text = [w.lower() for w in words if w not in ignore]
    cleaned_text2 = [w.replace(",", "") for w in cleaned_text]
    cleaned_text3 = [w.replace(".", "") for w in cleaned_text2]
    return cleaned_text3
```

```
def tokenize(sentences):
    words = []
    for sentence in sentences:
        w = word_extraction(sentence)
        words.extend(w)
        words = sorted(list(set(words)))
    return words
```

```
def texts_to_array():
    allsentences = []
    for i in range(1001):
        file_name = 'text' + str(i) + '.txt'
        path = 'texts/' + file_name
        sentence = Path(path).read_text()
        allsentences.append(sentence)
    return allsentences
```

```
def generate bow():
 allsentences = texts_to_array()
 global vocab
 vocab = tokenize(allsentences)
 bag arr = \prod
 LEN_VOC = len(vocab)
 for sentence in allsentences:
    words = word_extraction(sentence)
    bag_vector = [0]*LEN_VOC
    for w in words:
      for i,word in enumerate(vocab):
         if word == w:
           bag_vector[i] += 1
    bag_arr.append(bag_vector)
 numpy_array = numpy.array(bag_arr)
 transpose = numpy_array.T
 global matrix before trans
 matrix_before_trans = numpy_array.tolist()
 transpose_list = transpose.tolist()
 return transpose list, vocab
```

5.Przetworzony wstępnie otrzymany zbiór(document_matrix) danych mnożąc elementy bag-of-words przez inverse document frequency

$$IDF(w) = \log \frac{N}{n_w},$$

```
def inverse_document_frequency():
    global document_matrix
    document_matrix, voc = generate_bow()
    LEN_VOC = len(vocab)
    counter_words = [0] * (LEN_VOC)
    for i in range(LEN_VOC):
        for j in range(1001):
        if document_matrix[i][j] != 0:
            counter_words[i] += 1
        if counter_words[i] != 0:
            counter_words[i] = math.log(1001/counter_words[i])

for i in range(1001):
    for j in range(LEN_VOC):
        document_matrix[j][i] *= counter_words[j]
```

6. Cos i k najbardziej podobnych dokumentów

$$\cos \theta_j = \frac{\mathbf{q}^T \mathbf{d}_j}{\|\mathbf{q}\| \|\mathbf{d}_j\|} = \frac{\mathbf{q}^T \mathbf{A} \mathbf{e}_j}{\|\mathbf{q}\| \|\mathbf{A} \mathbf{e}_j\|}$$

```
def cos(vector1, vector2):
    cos = 0
    for i in range(len(vector1)):
        cos += (vector1[i]*vector2[i])
    len1 = 0
    len2 = 0
    for i in range(len(vector2)):
        len1 += vector1[i]**2
        len2 += vector2[i]**2
    len2 = numpy.sqrt(len1)
    len2 = numpy.sqrt(len2)

cos = cos/(len1*len2)
    return cos
```

```
def k_most_similar_texts(k):
    compare_document = []
    print(matrix_before_trans)
    input_bag_of_words = input_to_bag_of_words()
    for i in range(1001):
        similiar = cos(matrix_before_trans[i], input_bag_of_words)
        t = (similiar, i)
        compare_document.append(t)
    compare_document.sort(key = lambda x: x[0], reverse = True)

print("the most similar texts:")

for i in range(k):
    file_name = 'text' + str(compare_document[i][1]) + '.txt'
    path = 'texts/' + file_name
    print("{0} similiarity: {1}".format(path, compare_document[i][0]))
```

7. Normalizacja wektora

```
def normalize(v):
   norm=numpy.linalg.norm(v, ord=1)
   if norm==0:
      norm=numpy.finfo(v.dtype).eps
   return v/norm
```

Normalizacja wektorów w macierzy

```
def normalize_matrix():
    global normalized_matrix
    normalized_matrix = []
    for i in range(1001):
        normalized_matrix.append(normalize(matrix_before_trans[i]))
```

Funkcja pozwalająca wprowadzić tekst ze standardowego wejścia i przekształca go w bag of words

```
def input_to_bag_of_words():
    input_string= input(">>")
    LEN_VOC = len(vocab)
    words = word_extraction(input_string)
    bag_vector = [0] * LEN_VOC

for w in words:
    for i, word in enumerate(vocab):
        if word == w:
            bag_vector[i] += 1
return bag_vector
```

k najbardziej podobnych tekstów do tekstu wpisanego w konsoli

```
def k_most_similar_texts_normalize(k):
    compare_document = []

input_bag_of_words = input_to_bag_of_words()
    normalized_input_bag = normalize(input_bag_of_words)
    normalize_matrix()

for i in range(1001):
    similiar = cos(normalized_matrix[i], normalized_input_bag)
    t = (similiar, i)
    compare_document.append(t)
    compare_document.sort(key = lambda x: x[0], reverse = True)

print("the most similar texts:")

for i in range(k):
    file_name = 'text' + str(compare_document[i][1]) + '.txt'
    path = 'texts/' + file_name
    print("{0} similiarity: {1}".format(path, compare_document[i][0]))
```

Wynik wywołania tej funkcji dla wprowadzonego fragmentu tekstu z pliku text500.txt

```
/home/pawel/Desktop/Git/Mownit/venv5/bin/python /home/pawel/Desktop/Git/Mownit/lab4_SVD2/lab4.py 
>> Secondary particles military alliances fostered many social historians has shifted 
the most similar texts: 
texts/text500.txt similiarity: 0.4472135954999578 
texts/text138.txt similiarity: 0.18342535215472283
```

8. Usunięcie szumu

$$\mathbf{A} \simeq \mathbf{A}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^T = [\mathbf{u}_1 | \dots | \mathbf{u}_k] \left[egin{array}{ccc} \sigma_1 & & & \ & \ddots & \ & & \ddots & \ & & \sigma_k \end{array}
ight] \left[egin{array}{c} \mathbf{v}_1^T \ dots \ \mathbf{v}_k^T \end{array}
ight] = \sum_{i=1}^k \sigma_i \mathbf{u_i} \mathbf{v_i}^T$$

Funkcja zwracająca Ak

```
def svd_matrix(k_svd):
    U, S, VT = sparse.linalg.svds(normalized_matrix, k_svd)
    svd_matrix = U @ numpy.diag(S) @ VT
    return svd_matrix
```

```
def k_most_similar_texts_noise_removal(k, k_svd):
  compare_document = []
  input_bag_of_words = input_to_bag_of_words()
  normalized_input_bag = normalize(input_bag_of_words)
  normalize_matrix()
  svd = svd matrix(k svd)
  for i in range(1001):
    similiar = cos(svd[i], normalized_input_bag)
    t = (similar, i)
    compare document.append(t)
  compare_document.sort(key=lambda x: x[0], reverse=True)
  print("the most similar texts:")
  for i in range(k):
    file_name = 'text' + str(compare_document[i][1]) + '.txt'
    path = 'texts/' + file_name
    print("{0} similarity: {1}".format(path, compare_document[i][0]))
```

9. Wykonano test, gdzie ponownie wprowadzono fragment pliku text500.txt a)bez IDF

```
def k_most_similar_texts_noise_removal_test(k):
    for pow in [2,3,4,5,6,7,8,9]:
        print(f"{bcolors.HEADER} k = {2**pow} {bcolors.ENDC}")
        k_most_similar_texts_noise_removal(k, 2**pow)
```

Wynik testu:

```
the most similar texts:
texts/text641.txt similiarity: 0.04268050688485881
texts/text746.txt similiarity: 0.04254389972180626
k = 8
the most similar texts:
texts/text472.txt similiarity: 0.07218190801114147
texts/text624.txt similiarity: 0.07121057753935853
the most similar texts:
texts/text446.txt similiarity: 0.07747413153456259
texts/text245.txt similiarity: 0.07634682477562593
k = 32
the most similar texts:
texts/text500.txt similiarity: 0.2521029351966064
texts/text138.txt similiarity: 0.21424169879942392
k = 64
the most similar texts:
texts/text500.txt similiarity: 0.3021386979205278
texts/text138.txt similiarity: 0.22266389284008153
k = 128
the most similar texts:
texts/text500.txt similiarity: 0.3446394932153628
texts/text138.txt similiarity: 0.2246891350331475
k = 256
the most similar texts:
texts/text500.txt similiarity: 0.3958510591073781
texts/text138.txt similiarity: 0.22108973595279663
```

```
k = 512
>>Secondary particles military alliances fostered many social historians has shifted
the most similar texts:
texts/text500.txt similiarity: 0.4350456416339556
texts/text138.txt similiarity: 0.20190843208597947
```

Dla porównania wynik przed usunięciem szumu

```
/home/pawel/Desktop/Git/Mownit/venv5/bin/python /home/pawel/Desktop/Git/Mownit/lab4_SVD2/lab4.py 
>> Secondary particles military alliances fostered many social historians has shifted 
the most similar texts: 
texts/text500.txt similiarity: 0.4472135954999578 
texts/text138.txt similiarity: 0.18342535215472283
```

Wnioski

Przy wprowadzeniu 10 słów z pliku text500.txt algorytm znalazł z nim największe podobieństwo przy już k=32. Im większe k tym lepiej był rozpoznawany plik źródłowy. Znaczy skok podobieństwa nastąpił między k=16, a k=32. Myślę, że dla najoptymalniejsze k jest między 50, a 100, bo wtedy jest dość szybki wzrost podobieństwa między zdaniem z tekstu, a samym tekstem.

b) z IDF

IDF faworyzują słowa, które występują w niewielu dokumentach. Słowa występujące rzadziej (np. te które są związane bardziej z jakąś dziedziną, są bardziej fachowe) bardziej upodobniają dwa dokumenty niż słowa pospolite. W powyższym teście można zauważyć, że IDF pomogło znależć szybciej podobieństwo między zdaniem z tekstu, a samym tekstem.